

暑期讲义

作者：有80%信心的DSY

主旨：阿巴阿巴随便写点，慢慢丰富

序言：暂无

参考书籍：《机器学习》（周志华西瓜书），《统计学习方法》（李航），《deep learning book》，《Understanding Machine Learning: From Theory to Algorithms》，《High-dimensional probability: an introduction with applications in data science》，pytorch doc

私货极多欢迎批评，邮箱：madsy@mail.scut.edu.cn

想感谢的人：暂时没想好

献给XXXX

最近前面内容好像有个主旨：本讲义想从机器学习基本问题出发，讲明白对于神经网络甚至更广义的可微模型编程建模逻辑。

1机器学习基础概念

1.1集合与模型

1.1.1 事件集，Definition：

真实世界里我们研究对象数值建模化的集合 Ω 。

eg：如各种各样的图片，声音，文本，信号。

1.1.2 输入空间，Definition：

所有可能的输入元素组成的集合 \mathcal{X} ，事件集一定是输入空间。

1.1.3 输出空间，Definition：

所有可能的输出元素组成的集合 \mathcal{Y} ，事件集可以是输出空间。

1.1.4联合分布假设：

对于定义在 \mathcal{X} 和 \mathcal{Y} 上的随机变量 X, Y ，我们假设在 $\mathcal{X} \times \mathcal{Y}$ 上其存在联合分布。

1.1.5真实映射假设：

对于定义在 \mathcal{X} 和 \mathcal{Y} 上的随机变量 X, Y ，我们假设存在最优的映射 $Y = F(X)$ ， $P(x, y)$ 可以转换为 $P'(x)$ 。

1.1.6数据集（样本点观测集），Definition：

对应集合上定义的随机变量，观察/采样到的独立同分布的样本点集。

eg:比如对于 $\mathcal{X} \times \mathcal{Y}$ 上的数据集 $\{(x_i, y_i)\} \sim P(x, y)$

1.1.7模型，Definition：

定义在由 \mathcal{X} 到 \mathcal{Y} 的一个映射 f ，该模型既可以是概率模型 $P(x)$ ，也可以是非概率模型 $f(x)$

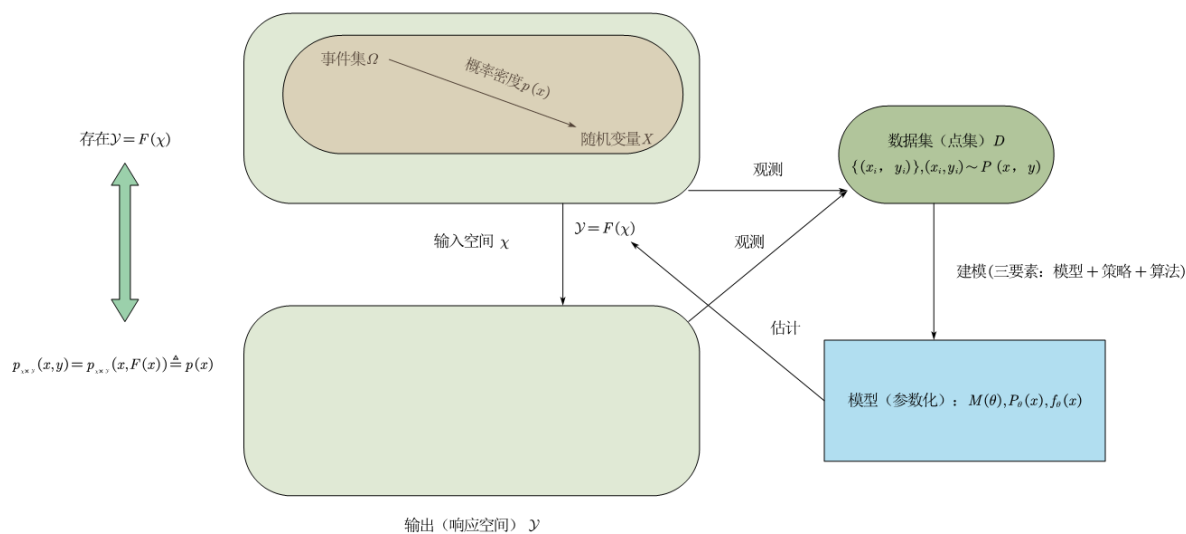
1.1.8假设空间，Definition：

对于我们假设所有可能模型 f 的集合 \mathcal{H} 。

1.1.9参数化模型及其假设空间, Definition:

定义在由 \mathcal{X} 到 \mathcal{Y} 的映射 f 由参数 θ 参数化, $\theta \in \Theta$,我们可以由 Θ 定义我们的假设空间 \mathcal{H}_Θ

eg: $\{f|f(x) = ax + b, a \in R, b \in R\}$ 定义了所有直线构成的假设空间。



1.2泛化误差及变分问题

1.2.1损失函数, Definition:

对于输出空间 $\mathcal{Y}, \forall a, b \in \mathcal{Y}$ 对于二元函数 $L(a, b), L$ 满足:

$$\begin{aligned} L(a, b) &\geq 0 \\ L(a, b) &= 0, \text{ if and only if } a = b \end{aligned}$$

eg:

如果 \mathcal{Y} 是一个度量空间, 则其上任意一个距离 d 都是损失函数。

1.2.3泛化误差, Definition:

对于一对输入输出空间 \mathcal{X} 和 \mathcal{Y} 上的随机变量 X, Y , 对任意模型 f ,我们称:

$$\begin{aligned} R_{\text{exp}}(f) &\triangleq E_{P, \mathcal{X} \times \mathcal{Y}}[L(\mathcal{Y}, f(X))] = \int_{\mathcal{X} \times \mathcal{Y}} L(\mathcal{Y}, f(x)) p(x, y) dx dy \\ \text{or } R_{\text{exp}}(f) &\triangleq E_{P, \mathcal{X}}[L(F(X), f(X))] = \int_{\mathcal{X}} L(F(x), f(x)) p'(x) dx \end{aligned}$$

What does Machine Learning do?

$$\min_{f \in \mathcal{H}} R_{\text{exp}}(f) = R(f)$$

1.2expand:泛函

1.2.3泛函, Definition:

集合 \mathcal{H} 是一个函数集合, R 是实数域, 我们定义 \mathcal{H} 到 R 的一个映射 $y = J(f)$ 为泛函。(本质是向量空间到标量的映射)。泛函一般由积分定义, 实际上我们已经接触过很多可以定义泛函的东西。

eg:

$$J(y) = \int_{x_0}^{x_1} \sqrt{1 + y'^2} dx$$

为二维平面上，过点 x_0, x_1 的所有可微曲线的泛函，该泛函的意义是这些曲线的长度。

$$J(p) = - \int p(x) \log p(x) dx$$

这是信息熵，衡量随机变量不确定性的泛函。

$$J(p) = KL(p||q) = \int p(x) \log \frac{p(x)}{q(x)}$$

这是关于 p 和 q 的一个损失。

当然泛化误差也可以定义一种泛函：

$$J(f) = R_{\exp}(f) \triangleq E_{P, \mathcal{X} \times \mathcal{Y}}[L(\mathcal{Y}, f(X))] = \int_{\mathcal{X} \times \mathcal{Y}} L(\mathcal{Y}, f(x)) p(x, y) dx dy$$

那么机器学习和泛函有什么关系？

1.2.4 泛函极值（变分问题） Definition:

我们称对于一个定义在 \mathcal{H} 上的泛函 $J(f)$ ，问题

$$\min_{f \in \mathcal{H}} J(f)$$

称之为泛函极值问题，也可以叫做变分问题。

机器学习的数学抽象本质是变分问题，我们试图要最小化泛化误差这个泛函：

$$\min_{f \in \mathcal{H}} R_{\exp}(f) = R(f)$$

对于由损失函数定义的变分问题，最优解是显然的，若真实映射 $F \in \mathcal{H}$, F 是最优解，不过很可惜，和传统的泛函分析面对的变分问题不同，我们无法解析的求解该变分问题。

原因有以下这么几个：

1.最重要的原因：我们无法解析知道输入空间输出空间确切的分布，和整个集合。我们所能拿到的只有数据集（样本点观测集）。

2.真实映射 F 是不可知的，我们的假设空间很难包含 F

...

那么如何去求解该变分问题？

答案：借助概率论，实分析，测度论的工具进行估计，用统计量建立的学习策略，统计量是可以计算的，再通过参数化模型把变分问题转换成数值优化问题。

1.3 Generalization Gap

1.3.1 经验损失， Definition:

对于可观测到的 N 个点集——数据集 $\{(x_i, y_i)\} \sim P(x, y)$

我们定义一种常见的学习策略 $\hat{R}(f)$:

$$\hat{R}(f) = \frac{1}{N} \sum_{i=1}^N L(F(x_i), f(x_i))$$

为经验损失。

变分问题裂解

考虑:

$$R(f) = [R(f) - \hat{R}(f)] + \hat{R}(f)$$

1.3.2 Generalization Gap, Definition:

我们定义如上裂解中方括号中的内容 $[R(f) - \hat{R}(f)]$ 叫做**Generalization Gap**, 此后记为**GP**。

这是个很重要的分解, 可以这么说, 这个看起来平常的式子, 把一个变分问题拆成两部分, 前面交给统计学家, 后面交给优化学家。

抽象理解:

对于**GP**问题, 统计学家要干的事情就是通过概率论, 实分析, 测度论等工具, 对假设空间 \mathcal{H} 建立如下依概率不等式结论:

$$\forall \varepsilon > 0, P(\exists f \in \mathcal{H}, GP \geq \varepsilon) \leq \frac{m(d_{\mathcal{H}})}{g(N) * h(\varepsilon)} \quad (1)$$

或者等价的

$$\forall \varepsilon > 0, P(\forall f \in \mathcal{H}, GP \leq \varepsilon) \geq 1 - \frac{m(d_{\mathcal{H}})}{g(N) * h(\varepsilon)} \quad (2)$$

其中 $d_{\mathcal{H}}$ 的含义是假设空间的一个复杂度度量, 如果 \mathcal{H} 是一个有限集合, 则 d 可以是其元素个数, 对于无限集合, 我们后面会介绍他的一个复杂度度量VC Dimension, N 是观测到的数据量, ε 是我们想要GP误差限, 其中 m, g, h 都是一个多项式或者指数级别的函数。

也就是说根据我们的数据量, 我们能以 $1 - \frac{m(d_{\mathcal{H}})}{g(N) * h(\varepsilon)}$ 的把握把**GP**控制在 ε 以内。

1.3.3 Probability Approximate Correct Learnable (PAC可学习)

若假设 \mathcal{H} 空间对于真实映射 F , 存在 $\hat{R}(f)$ 使得不等式 (2) 成立, 则我们称 F 对于 \mathcal{H} 是**PAC Learnable**的 (PAC可学习)。

注意! :

改概念不等价于**GP**依概率收敛到0!!!!!! (依测度收敛到0只是必要条件)

这里比**GP**依概率收敛到0要求更强!!!!

PAC Learnable GP 一定依概率收敛到0

GP依据概率收敛到0不一定PAC Learnable

重要的是要有一个和 $d_{\mathcal{H}}, N, \varepsilon$ 有关的概率Bound, 要能控制。

从统计的角度理解就是 $\hat{R}(f)$ 是 $R(f)$ 的弱相合统计量是**PAC Learnable**的一个必要条件。

定理1.3.4: 有限假设集理论

对于输入空间 \mathcal{X} 和布尔输出空间 $\mathcal{Y} = \{0, 1\}$, 我们的假设空间 \mathcal{H} 有限, 即 $\mathcal{H} = \{f_1, f_2, \dots, f_d\}$ 。

我们有:

$$\forall \varepsilon > 0, P(\forall f \in \mathcal{H}, GP \leq \varepsilon) \geq 1 - \frac{d}{\exp\{-2N\varepsilon^2\}}$$

即有限假设空间对于任意布尔映射是**PAC Learnable**。

该证明需要用到**Hoeffding inequality**:

定理1.3.4.1 Hoeffding inequality (霍夫丁不等式)

X_1, \dots, X_n 为有界独立随机变量, 即 $A_i \leq X_i \leq B_i, 1 \leq i \leq n$. 对于任意 $\varepsilon > 0$, 和任意 $t > 0$,

$$P\left(\sum_{i=1}^n (X_i - E[X_i]) \geq \varepsilon\right) \leq \exp\left(-t\varepsilon + \frac{t^2}{8} \sum_{i=1}^n (B_i - A_i)^2\right)$$

进一步:

$$P\left(\sum_{i=1}^n (X_i - E[X_i]) \geq \varepsilon\right) \leq \exp\left(-\frac{2\varepsilon^2}{\sum_{i=1}^n (B_i - A_i)^2}\right)$$

而要证明**Hoeffding inequality**我们先要需要证明高维统计如下几个引理:

引理1.3.4a: Markov inequality (马尔可夫不等式)

$$X \geq 0, \forall \varepsilon > 0, P(x \geq \varepsilon) \leq \frac{1}{\varepsilon} EX.$$

proof:

$$\begin{aligned} EX &= \int_0^{+\infty} x dF(x) \geq \int_{\varepsilon}^{+\infty} x dF(x) \geq \varepsilon \int_{\varepsilon}^{+\infty} dF(x) = \varepsilon P(x \geq \varepsilon). \\ \therefore P(x \geq \varepsilon) &\leq \frac{1}{\varepsilon} EX. \end{aligned}$$

定理1.3.4.1 Hoeffding inequality

proof:

我们考虑:

$$Y_i \triangleq X_i - EX_i, EY_i = 0$$

可以看出:

$$a_i = A_i - EX_i \leq Y_i \leq b_i = B_i - EX_i$$

原问题等价：

$$P(\Sigma Y_i \geq \varepsilon) \leq \exp\left(-t\varepsilon + \frac{t^2}{8}\Sigma(b_i - a_i)^2\right)$$

考虑：

$$P(\Sigma Y_i \geq \varepsilon) = P(e^{t\Sigma Y_i} \geq e^{t\varepsilon})$$

由**Markov inequality**：

$$P(e^{t\Sigma Y_i} \geq e^{t\varepsilon}) \leq e^{-t\varepsilon} \cdot E[e^{t\Sigma Y_i}]$$

因为 Y_i 独立：

$$P(e^{t\Sigma Y_i} \geq e^{t\varepsilon}) \leq e^{-t\varepsilon} \cdot \prod_i^N E[e^{tY_i}]$$

又因为 $a_i \leq Y_i \leq b_i$,